

# 의료영상

## AI 해커톤

손종욱

양유진

유지수

홍정민

# ***CONTENTS***

---

## 01 개요

## 02 적용 기법

- 전처리
- 인공지능 모델 구조
- 추론 단계 데이터 증대 기법

## 03 질환별 세부 적용 사항

- 심장비대증
- 기흉
- 유방암

## 04 결과

## 05 결론

## 06 참고문헌

# 개요

팀 소개 및 분석 과정 개요

---

## ■ 목표

- 의료영상을 활용하여 질병 진단을 보조할 수 있는 인공지능 솔루션

## ■ 소속

- 성균관대학교 산업공학과

## ■ 팀원


- 4명 (손종욱, 양유진, 유지수, 홍정민)

## ■ 분석 대상


- 심장비대증 (Cardiomegaly)
- 기흉 (Pneumothorax)
- 유방암 (Breast Cancer)



심장비대증



기흉



유방암

# 개요

팀 소개 및 분석 과정 개요

## ■ 프레임워크

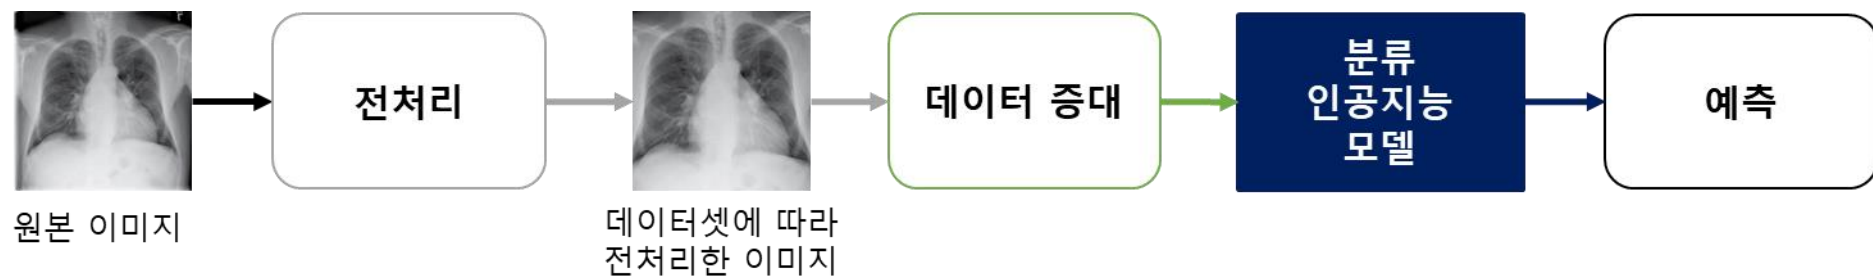


Fig 1. 본 해커톤 내 프레임워크

- 전처리
  - 각 데이터셋의 특징에 따라 전처리
- 데이터 증대
  - 다양하게 변형된 이미지를 생성하여 가상으로 데이터를 증대 시키는 방법
  - 학습 단계에서 하나의 클래스에 대해 다양한 이미지를 학습하기에 모델의 일반화 성능을 향상 시킬 수 있음

# 적용기법

## 전처리

### ■ 전처리 (Preprocessing)

- 질환별로 영상에 나타나는 시각적 특징을 고려한 전처리
- 전처리 결과 시각화를 통해 직관적인 인사이트 도출
- 전처리 결과가 모델 성능의 결정적인 역할



MONOCHROME2



MONOCHROME1

Fig 2. DICOM 파일 방식에 따른 차이

## ■ Contrast Limited Adaptive Histogram Equalization (CLAHE)

- 대비가 낮은 이미지는 주변 세포와 이상이 있는 부분이 구분이 어려움
- 대비가 낮은 이미지의 대비를 높여 모델이 질병을 검출할 수 있도록 도와줌

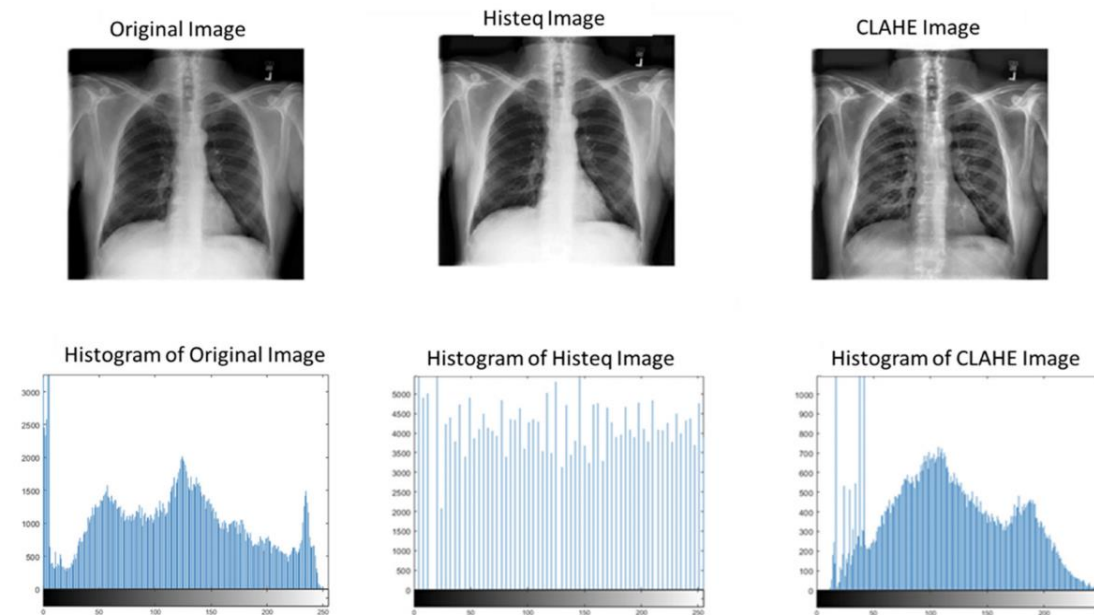


Fig 3. 원본 이미지와 히스토그램 균일화 기법 (histogram equalization methods)이 적용된 이미지의 히스토그램

# 적용기법

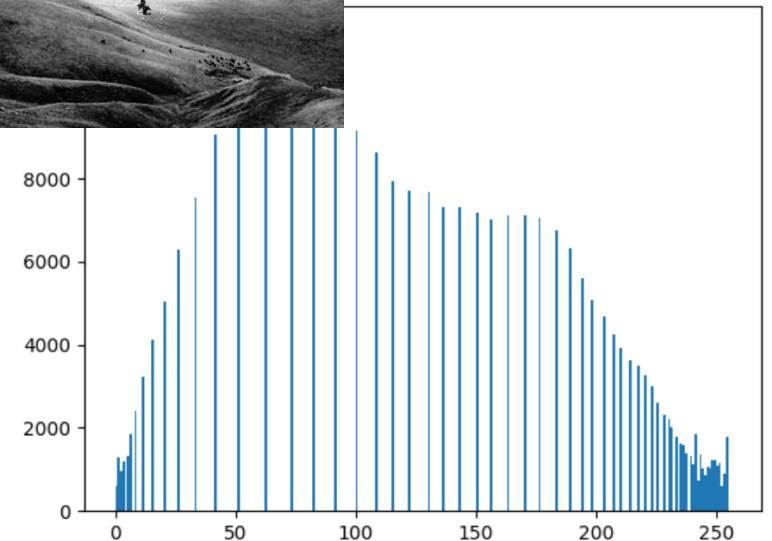
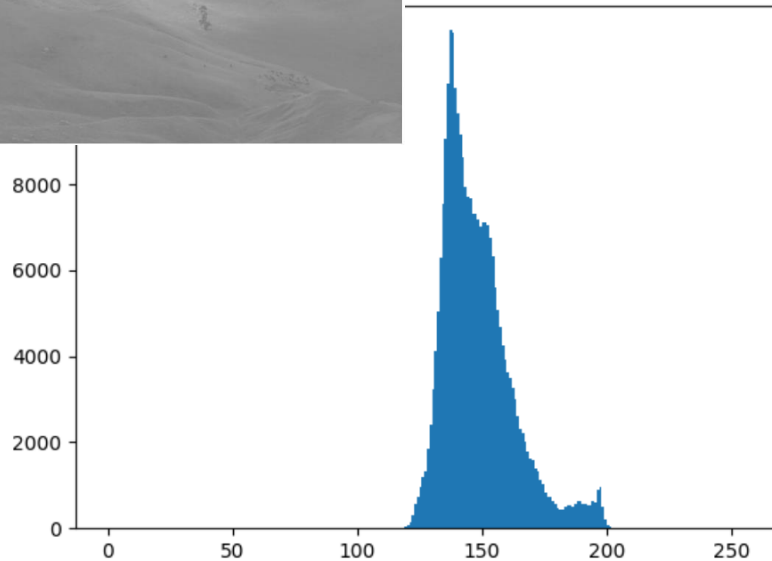
전처리

## ■ 히스토그램 균일화 (Histogram Equalization)

- 좁은 범위에 집중되어 있는 픽셀값들을 전체 범위에 넓게 분포하도록 변환하는 방법



히스토그램 균일화



## ■ Contrast Limited Adaptive Histogram Equalization (CLAHE)

- 선택적 히스토그램 균일화 (Adaptive Histogram Equalization)
  - 이미지를 겹치지 않는 타일 단위로 나누어 히스토그램을 균일화
  - 한 타일 안에 픽셀의 범위가 몰려 있으면 이를 균일화 하는 과정에서 노이즈 증폭 문제 발생
- 히스토그램의 높이를 제한하는 Contrast Limiting 방법을 통해 노이즈 증폭 문제를 해결
  - 특정 히스토그램의 높이(clip limit)를 넘는 픽셀들을 재분배하여 히스토그램의 높이를 제한

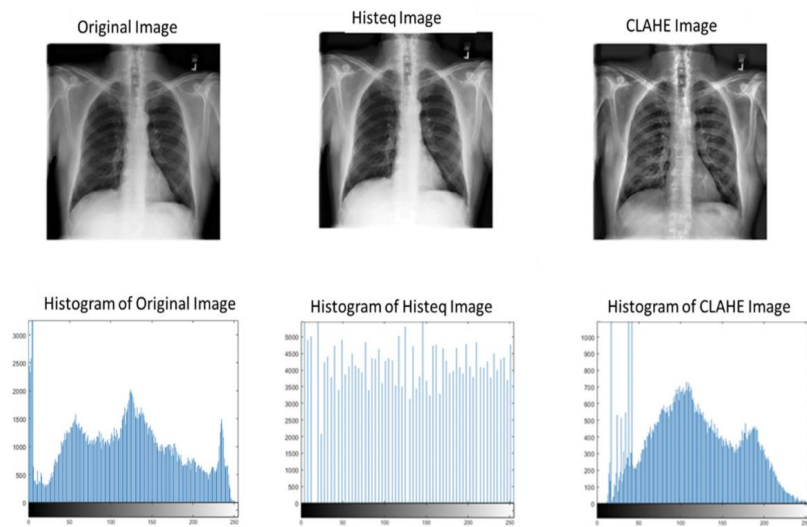


Fig 3. 원본 이미지와 히스토그램 균일화 기법 (histogram equalization method) 이 적용된 이미지의 히스토그램




Fig 4. Contrast Limiting Method



# 적용기법

## 인공지능 모델 구조

- Inception (Szegedy, Christian, et al. "Going deeper with convolutions.")
  - 합성곱 신경망\* 기반의 인공지능 모델
  - 성능은 대폭 상승하지만 연산량은 약간만 증가한다는 장점
    - 모델이 깊을수록 성능이 증가하지만 연산량이 기하급수적으로 증가
    - 깊은 모델 구조에도 불구하고 과도한 연산량 문제없이 각 단계에서 성능을 상당히 증가시킬 수 있음




Fig 5. Inception의 전체적인 구조

\*합성곱 신경망 (Convolutional Neural Network, CNN)

- 이미지 또는 영상을 처리하기 적합하며 뛰어난 성능을 보이는 인공지능 모델

## ■ SE-Blocks (Squeeze and Excitation Blocks)

- 합성곱 신경망이 추출하는 여러가지 정보들 중에서 중요한 정보에 더 집중할 수 있도록 하는 구조
- 합성곱 신경망의 종류에 상관 없이 적용할 수 있음
- 추가적인 계산량이 적지만 성능 향상이 큼
- Squeeze
  - 합성곱 신경망이 추출하는 여러가지 정보들을 전체적으로 요약
- Excitation
  - 요약된 정보들 중에서 중요한 정보에 가중치를 부여




Fig 6. SE-Blocks의 전체적인 구조

- SE-Inception
  - SE-Blocks + Inception




Fig 7. SE-Inception 상세 구조

## ■ 추론 단계 데이터 증대 기법 (Test-time Data Augmentation, TTA)

- 추론 단계에서 수행하는 데이터 증대
- 데이터 증대로 학습된 모델이 추론 단계에서 주어진 이미지를 다양한 관점으로 판단
- 예측하기 어려운 이미지에 대해서도 여러 번의 판단을 통해 예측 성능 향상을 기대할 수 있음




Fig 8. 추론 단계 데이터 증대 기법 개요

# 질환별 세부 적용 사항

## 심장비대증

### ■ 심장비대증

- 심흉곽비 (cardiothoracic ratio,  $CTR=A+B/C$ )가 0.5 이상 일 때 양성
- 전처리
  - 이미지 자르기
    - 불필요한 부분을 제거하여 모델이 심장 부분에만 집중할 수 있도록 함
  - 불필요한 시각적 특징 제거
    - 신체에 비해 너무 밝은 글자나 전극 부분의 밝기 줄이기
  - CLAHE
    - 이미지 대비 향상




Fig 9. cardiothoracic ratio

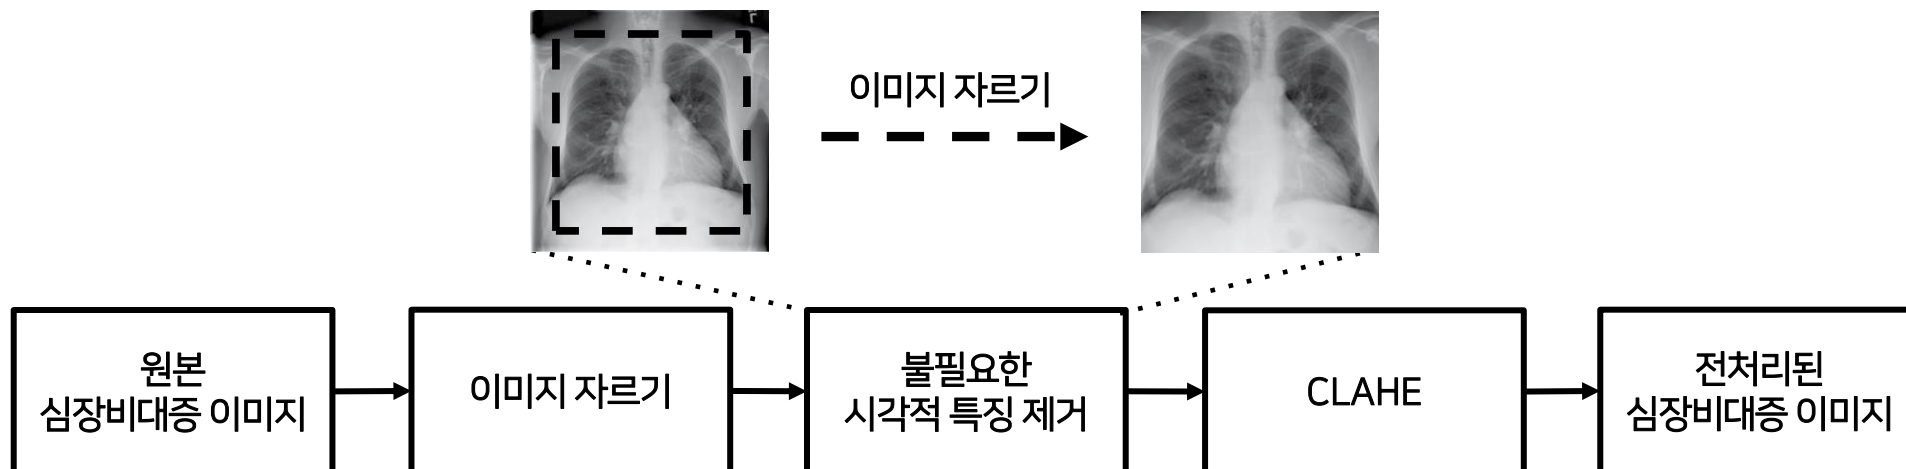


Fig 10. 심장비대증 전처리 과정

# 질환별 세부 적용 사항

심장비대증

## ■ 추론 단계

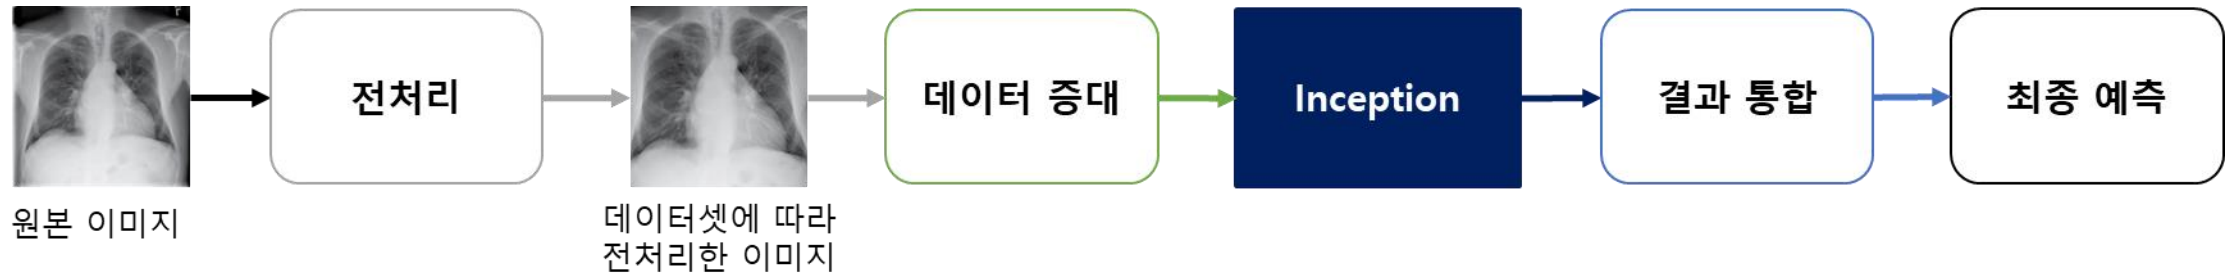


Fig 11. 심장비대증 양성 판단 과정

# 질환별 세부 적용 사항

## 기흉

### ■ 기흉

- 흉부 X-ray 영상에서 폐에 공기가 찬 부분의 경계선이 나타남
- 전처리
  - 불필요한 시각적 특징 제거
    - 신체에 비해 너무 밝은 글자나 전극 부분의 밝기 줄이기
  - CLAHE
    - 이미지 대비 향상




Fig 12. (a) 기흉이 있는 X-ray 이미지  
(b) (a)에서 기흉의 위치와 형태를 표현한 마스크




Fig 13. 기흉 전처리 과정

# 질환별 세부 적용 사항

기흉

## ■ 추론 단계

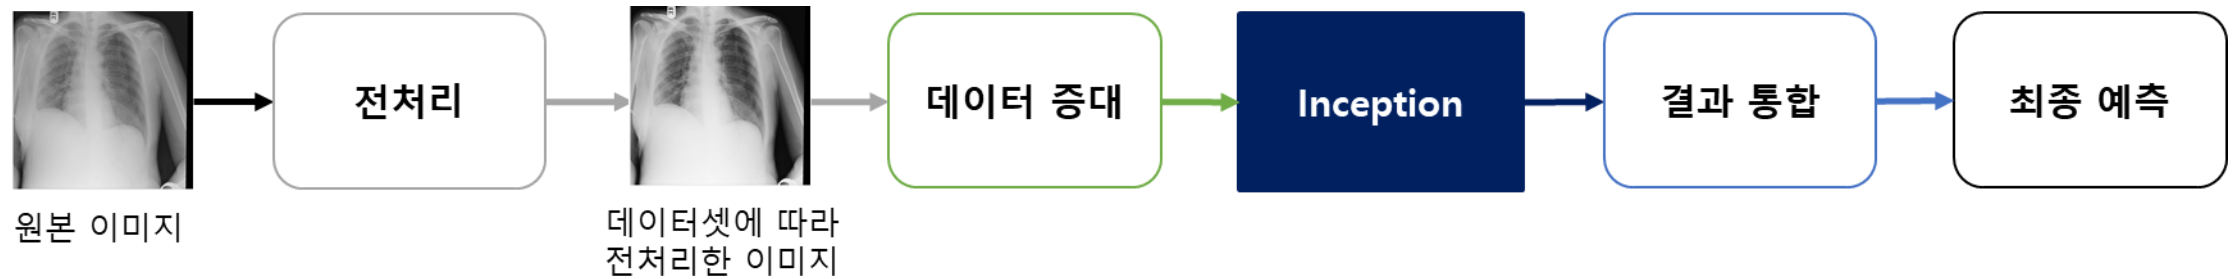


Fig 14. 기흉 양성 판단 과정





# 질환별 세부 적용 사항


## 유방암

### ■ 유방암

- 악성 종양이 X-ray 영상에서 뿌옇게 나타남
- 전처리
  - 히스토그램 수동 조정
    - 같은 검은색이지만 아무것도 없는 검은 배경과 유방 조직의 검은색 값이 다른 문제
      - 배경은 0에 가까운 값, 유방 조직은 0.5 정도의 밝은 값
      - 이미지 파일로 저장 시 전체적으로 뿌옇게 보이는 문제 발생
    - 모두 같은 검은색으로 만들어 주기 위한 작업
      - 유방 조직의 검은색이 이미지의 가장 어두운 부분이 되게끔
  - CLAHE
    - 이미지 대비 향상



정상적인 이미지 히스토그램



비정상적인 이미지 히스토그램

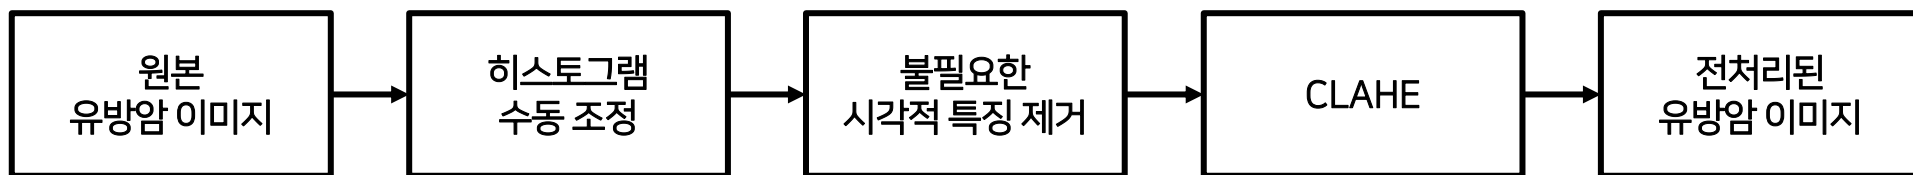


Fig 15. 유방암 전처리 과정

# 질환별 세부 적용 사항

유방암

## ■ 추론 단계

- 환자 별 4장의 이미지 결과값의 합이 임계값( $\delta$ ) 0.6 보다 크면 양성




Fig 16. 환자별 유방암 양성 판단 과정

# 결과

결과

## ■ 해커톤 결과

질환	모델	정확도	순위
심장비대증	CMC	62.95%	5
심장비대증	Classification	98.57%	1
기흉	Classification	80.00%	3
유방암	Classification	82.65%	3

## ■ 요약

- 심장 비대증, 기흉, 유방암 이상 여부를 **분류 모델**을 통해 판단
- 각 데이터셋에 따른 데이터 전처리 수행
- 각 데이터셋마다 하나의 모델만을 학습하고 추론하는데 사용
- 데이터 증대를 학습 단계와 추론 단계에 적용하여 최종 분류 성능 향상

## ■ 의의

- 질환별로 적합한 전처리를 적용하여 성능 향상에 큰 기여
- 모델 여러 개를 사용해야하는 앙상블 기법과 달리 각 데이터셋 마다 하나의 모델만을 사용하였기에 **모델 경량화** 가능
- TTA를 통해 예측의 불확실성을 낮춰 **최종 분류 성능 향상**

# 참고문헌

---

- Rahman, Tawsifur, et al. "Exploring the effect of image enhancement techniques on COVID-19 detection using chest X-ray images." Computers in biology and medicine 132 (2021): 104319.
- Cho, Y., Kim, J.S., Lim, T.H. et al. Detection of the location of pneumothorax in chest X-rays using small artificial neural networks and a simple training process. Sci Rep 11, 13054 (2021).
- Szegedy, Christian, et al. "Going deeper with convolutions." Proceedings of the IEEE conference on computer vision and pattern recognition. 2015.
- Hu, Jie, Li Shen, and Gang Sun. "Squeeze-and-excitation networks." Proceedings of the IEEE conference on computer vision and pattern recognition. 2018.

감사합니다